

Curso: Machine Learning (CS3061)

Proyecto 1: Clasificación

Prof. D.Sc. Manuel Eduardo Loaiza Fernandez

Instrucciones Generales

El informe debe ser redactado en LaTeX utilizando la plantilla oficial del curso. La extensión máxima es de 8 páginas (sin considerar apéndices). Se requiere la inclusión de un enlace a un repositorio de GitHub o Google Colab con el código funcional, organizado y con una semilla (*seed*) definida para asegurar la replicabilidad. Respecto a los estándares visuales, queda estrictamente prohibido el uso de capturas de pantalla de la terminal o tablas de código para presentar resultados; todas las tablas deben ser nativas de LaTeX. Se requiere incluir un mínimo de 2 y un máximo de 4 gráficos en total dentro del informe, con leyendas legibles (mínimo 10pt) y ejes debidamente etiquetados.

1. Selección del Proyecto

Se debe elegir uno de los siguientes desafíos de consultoría:

(a) *Mantenimiento Predictivo: Turbofans de la NASA (FD002)*

Clasificación binaria (Sano (clase 0) vs. Crítico (clase 1)). El objetivo es crear un sistema de alerta temprana gestionando **6 condiciones operacionales** y alta colinealidad entre 21 sensores.

Datos: Dataset Motores NASA (FD002)

Kaggle: Competencia NASA FD002

(b) *Análisis de Retención: Predicción de Churn (Telecom)*

Clasificación binaria (Retenido vs. Fugado). El reto es manejar el **desbalance de clases** y procesar datos mixtos (categóricos y numéricos) para predecir cancelaciones.

Datos: Dataset Churn Telco

Kaggle: Competencia Churn Telco

Recomendaciones técnicas:

- Limpieza: de datos.
- **Umbral:** Optimizar el *threshold* de decisión según la matriz de costos, no usar el 0.5 por defecto.
- **Validación:** Emplar técnicas de Cross-Validation para mantener la proporción de clases.

2. Herramientas Recomendadas

Se recomienda el uso del stack científico de Python: *Pandas*, *NumPy*, *Scikit-learn*, *Matplotlib* y *Seaborn*. Para el caso (a), se sugiere explorar librerías de extracción de características en series de tiempo como *TsFresh* o *PyTS*. El uso de otras librerías para preprocesamiento y métricas es libre, siempre que se justifique su necesidad.

3. Implementación de Modelos (Actividad Requerida)

Se deben implementar y comparar al menos dos métodos de clasificación vistos en clase (por ejemplo: Regresión Logística, SVM, KNN, Árboles de Decisión o Métodos de Ensamble). Se recomienda no limitarse a elegir modelos al azar; es necesario explicar por qué estos algoritmos resultan adecuados para la naturaleza del dataset seleccionado (considerando aspectos como no linealidad, robustez al ruido o dimensionalidad).

4. Evaluación de Resultados

Se deben reportar y analizar las métricas de F1-Score, Accuracy y Matriz de Confusión (esta última presentada como un *heatmap*). Se requiere un análisis de los resultados en términos de la teoría aprendida, discutiendo el equilibrio entre sesgo y varianza (*Bias-Variance Tradeoff*) y el efecto de las técnicas de regularización en el desempeño.

5. Estructura y Estándares del Informe

El informe debe seguir obligatoriamente el siguiente orden y estándares:

1. **Resumen Ejecutivo:** Máximo 150 palabras resumiendo el problema y el hallazgo principal.
2. **Ingeniería de Datos y Formulación:** Explicación de la definición de la variable objetivo, inclusión de una tabla nativa en LaTeX con las nuevas variables creadas y justificación técnica del preprocesamiento (escalado y manejo de desbalance).
3. **Metodología y Optimización:** Presentación de una tabla con los hiperparámetros ajustados, rangos explorados en validación cruzada (*Cross-Validation*) y los valores óptimos seleccionados.
4. **Análisis de Costo-Beneficio:** Definición de una Matriz de Costos monetaria (ej. costo de Falsos Negativos vs. Falsos Positivos). Se debe calcular el Costo Total Esperado sobre el conjunto de prueba y justificar el ajuste del umbral de decisión (*threshold*).
5. **Conclusiones:** Resumen de limitaciones, lecciones aprendidas y recomendaciones.

6. Contribution Statement

Se debe incluir un resumen detallado de la contribución específica de cada miembro del equipo y su porcentaje de participación.

7. Evaluación de casos de regresión lineal y regresión logística

Se debe procesar los siguientes tres casos de forma similar a lo hecho en los trabajos prácticos, osea aplicar "feature engineering".^{en} cada caso y evaluar de forma independiente el comportamiento de los parámetros o variables dentro de un caso y luego la versión multivariable para calcular el (los) modelos de regresión lineal y/o no lineal según corresponda en el caso analizado.

Adicionalmente, se pedirá convertir o adaptar el modelo de regresión lineal o no lineal para convertirse en un modelo de clasificación, en ese mismo sentido se pedirá que se haga una evaluación del modelo analizando el comportamiento de cada variable así como el modelo con la versión multivariable.

Validar la contribución probabilística de cómo comporta el Decision Boundary con la evaluación de cada parámetro individualmente y en versión multivariable o multiparámetro.

Ejercicio A — Precio de Vivienda

Una inmobiliaria recopila datos de 14 propiedades. Se desea predecir el precio de venta (USD) en función de cuatro variables: área (m²), número de habitaciones, antigüedad (años) y distancia al centro de la ciudad (km). A mayor distancia del centro, menor es el precio esperado ($w_4 < 0$).

$$\hat{y} = w_0 + w_1 \cdot \text{área} + w_2 \cdot \text{hab} + w_3 \cdot \text{antigüedad} + w_4 \cdot \text{distancia}$$

Dataset Completo (14 propiedades)

Área (m ²)	Habitaciones	Antigüedad (años)	Distancia (km)	Precio (USD)
95	4	13	12.5	171,600
123	2	14	8.0	216,200
118	2	22	15.0	196,900
96	4	8	5.5	190,200
182	4	19	9.0	305,700
86	4	5	3.5	180,100
63	2	7	18.0	133,600
193	2	3	4.0	320,000
155	2	29	22.0	242,700
128	2	3	6.5	216,800
195	5	18	7.5	357,400
115	5	22	20.0	219,800
105	3	10	2.0	198,500
140	3	6	14.0	241,300

Parte 1 — Regresión Lineal Múltiple

Etapas 1.1 — Gradiente Descendiente a Mano (Versión Mínima)

Para afianzar la mecánica del algoritmo, realice los cálculos a mano (puede presentar su procedimiento en hoja cuadriculada o tableta gráfica). Para esta etapa, utilizaremos solo los **3 primeros registros** y una única característica (**Área**).

Para facilitar el cálculo manual, los valores han sido escalados (Área en cientos de m², Precio en cientos de miles de USD):

x_1 : Área (100s m ²)	y : Precio (100k USD)
0.95	1.71
1.23	2.16
1.18	1.96

1. Ejecute exactamente **4 iteraciones** del Gradiente Descendiente.
2. Utilice los siguientes valores iniciales: Pesos $\mathbf{w} = [w_0 = 0, w_1 = 1, 0]^\top$ y un Learning Rate $\alpha = 0,1$.

3. Reporte el error (MSE), los gradientes calculados y la actualización de los pesos en cada iteración.

Etapa 1.2 — Solución Computacional (Dataset Completo)

Utilice Python y el dataset completo de 14 propiedades y 4 características.

4. **Preprocesamiento:** Construya la matriz $\mathbf{X}$ de dimensiones (14×5) e $\mathbf{y}$ como vector columna. Verifique los rangos de las variables y aplique **Normalización Z-score** a las características antes de entrenar.
5. **Ecuación Normal:** Aplique $\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ y reporte los cinco coeficientes $w_0, \dots, w_4$. (Nota: Asegúrese de adaptar la ecuación si usó datos normalizados).
6. **Gradiente Descendiente (Código):** Implemente GD mediante código. Utilice valores iniciales razonables para un entorno computacional: $\mathbf{w} = \mathbf{0}$, $\text{lr} = 0,01$ y **5000 épocas**. Muestre la evolución del MSE cada 500 épocas.
7. **Interpretación Económica:** Verifique los signos de los pesos obtenidos computacionalmente. ¿Tienen sentido económico respecto a área, habitaciones, antigüedad y distancia? Explique.
8. **Predicción:** Utilizando su modelo final, prediga el precio de una casa de 120 m², 3 habitaciones, 10 años de antigüedad y 7 km del centro.

Parte 2 — Regresión Logística: ¿Precio > \$200,000?

$$y = \begin{cases} 1 & \text{PREMIUM: Precio} > \$200,000 \\ 0 & \text{ESTÁNDAR: Precio} \leq \$200,000 \end{cases} \quad \hat{p} = \sigma(w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4)$$

Etapa 2.1 — Variable objetivo binaria

1. Cree `y_bin = (y > 200000).astype(int)`. ¿Cuántas propiedades quedan en cada clase? ¿Está balanceado el dataset?

Etapa 2.2 — Modelos logísticos univariados

Para cada feature, ajuste un modelo univariado con GD ($\text{lr} = 0,01$, 2000 épocas) usando Binary Cross-Entropy en Python.

2. **Solo Área (x_1):** Reporte w_0, w_1 y accuracy. ¿El área sola es buen predictor?
3. **Solo Habitaciones (x_2):** Reporte w_0, w_2 y accuracy.
4. **Solo Antigüedad (x_3):** Reporte accuracy. ¿La antigüedad reduce la probabilidad de ser PREMIUM?
5. **Solo Distancia (x_4):** Reporte accuracy.

Etapla 2.3 — Modelo logístico completo (4 features)

6. Ajuste el modelo completo con las 4 características ($\text{lr} = 0,01$, 3000 épocas). Reporte $w_0 \dots w_4$.
7. Compare las accuracies de los 5 modelos (4 univariados + completo). Construya la matriz de confusión 2×2 .
8. Prediga la clase de una propiedad de 175 m², 4 hab., 8 años y 6 km del centro. ¿Cuál es $P(\text{PREMIUM})$?